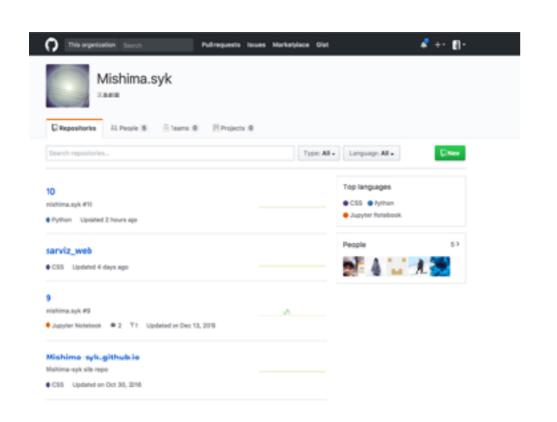
Machine Learning を流れるようにw

祝!

10th anniversary Mishima.syk!



https://github.com/Mishima-syk

あとで資料とコードはpushします。

Who am I?

- Twitter: @iwatobipen
- 業種: Medicinal Chemist
- 興味: Chemoinformatics, Organic Synthesis
- 言語: Japanese, Python, Java Script, R

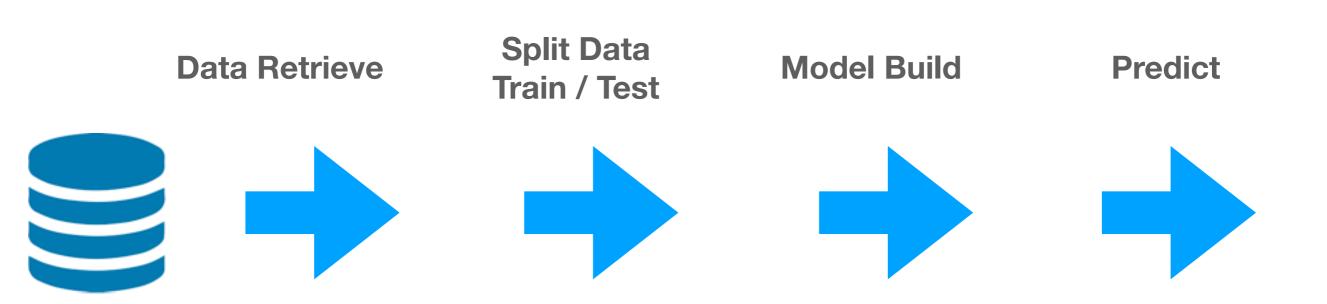


Today's topics

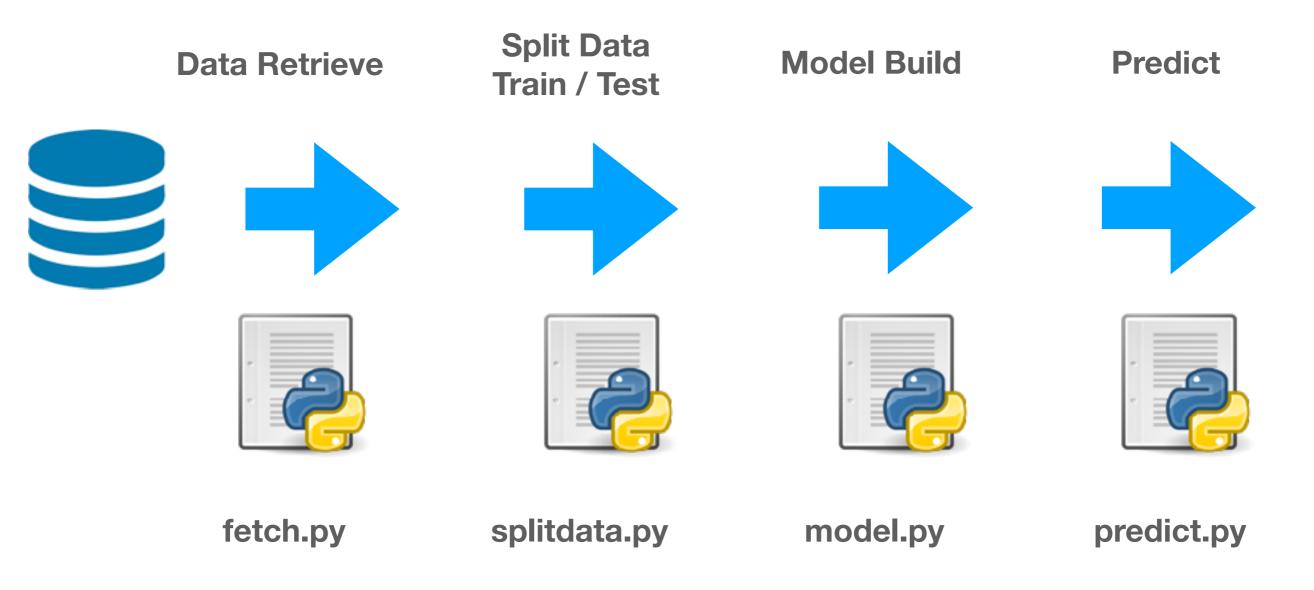
- Use pipeline / machine learning!
- Use Luigi!

早速

Machine Learningの流れを考えます



開発初期だとコードの断片を作ってとりあえず動かしたい



Run!









fetch.py

splitdata.py

model.py

predict.py

```
$python fetch.py
$python splitdata.py
$python model.py
$python predict.py
```

とか

```
if __name__ == '__main__':
    fetch()
    splitdata()
    model()
    predict()
```

But....

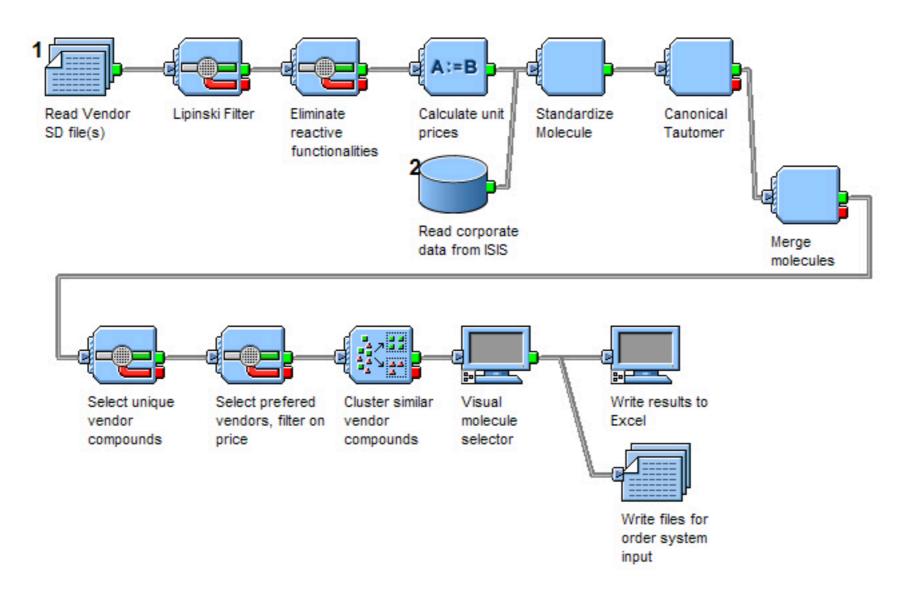
デバックがしにくい、、、 途中までうまく行ってたのに最初からやり直し、書き直し 全部まとめるとそれはそれで面倒なこともある。

```
$python fetch.py
$python splitdata.py
$python model.py
$python predict.py
```

or

```
if __name__ == '__main__':
    fetch()
    splitdata()
    model()
    predict()
```

でPipelineすっきりさせたいのです



俺の出番か!



What is Utile ?

- A Python Framework for data flow definition and execution.
- 音楽配信サービスを展開するSpotifyが開発
- All Python
- Pipでインストールできます





Luigiの基本構成

```
# task.py
import luigi
class FirstTask( luigi.Task ):
  def requires( self ):
     return []
  def output( self ):
     return luigi.LocalTarget( "hogehoge.txt" )
  def run( self ):
     with self.output().open('w') as output:
       " do something "
        output.write('hogehoge')
class SecondTask( luigi.Task ):
  def requires( self ):
     return FirstTask()
  def output( self ):
     return luigi.LocalTarget( "hogehoge2.txt")
  def run( self ):
     " do something "
        output.write('hogehoge2')
if __name__ == "__main__":
  luigi.run()
```

requires, output, runセット

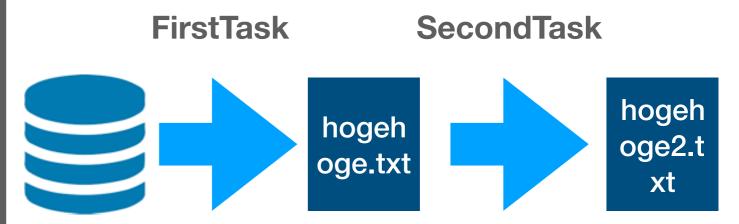
requires: 依存するタスク

output:タスクの出力

=>pickleは永続化に向かない

run:実際の実行部分

=>withで書くこと推奨



Run the Task

\$ python task.py SecondTask —local-scheduler

とりあえずローカルで実行するのなら

-local-schedulerを指定するといい。

Central-schedulerを使うとタスクの実行状況などが

可視化される(後で実際に動かします)。

FirstTask => SecondTaskのように実行される。

FistTaskと指定すればそこで止めることも可能です。

Parameter handling

\$ python task.py Task —local-scheduler —param hogehoge

```
# task.py
import luigi
class Task( luigi.Task ):
  param = luigi.Parameter()
  def requires( self ):
     return []
  def output( self ):
     return luigi.LocalTarget( "hogehoge.txt" )
  def run( self ):
     with self.output().open('w') as output:
       " do something "
        param = self.param
        output.write('hogehoge')
if __name__ == "__main__":
  luigi.run()
```

実際にやってみる

• Retrieve data from Local ChEMBL DB*ここは前もって設定必要です。僕の環境のverが22ですがそこはスルーしてください。

- Vectorize Data
- Train Test Split
- Model Build
- Model Test / Prediction

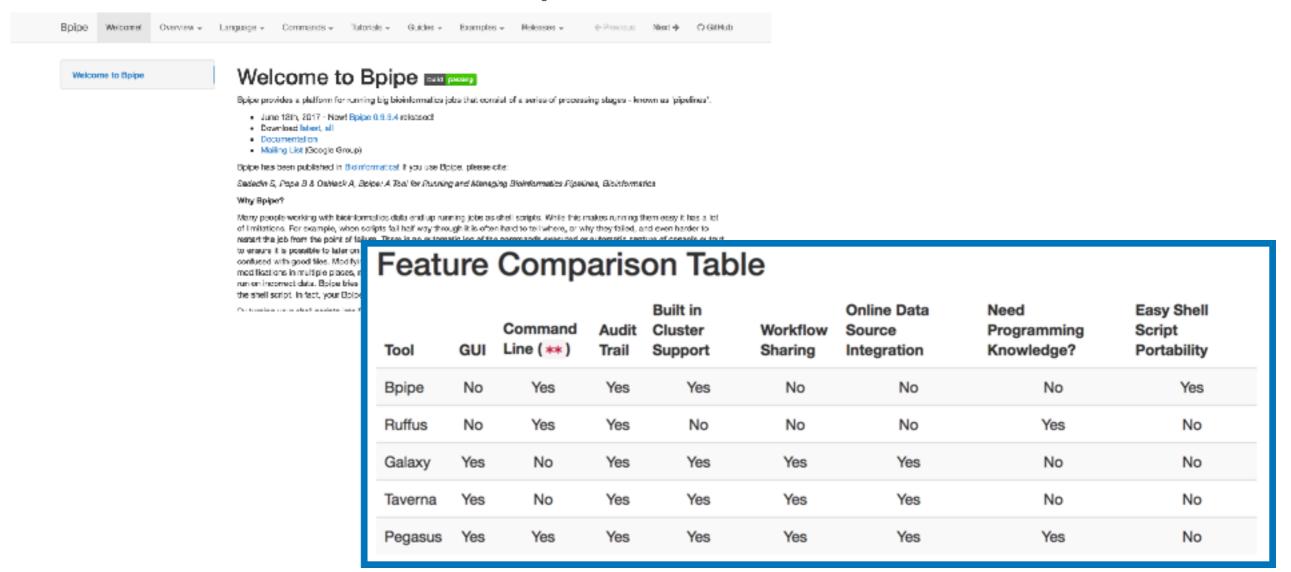
Requirements

- RDKit
- Psycopg2
- Scikit-learn
- Luigi
- Pandas

Go to Code !!!!

おまけ 1 For Bioinformatics

http://docs.bpipe.org/Examples/RNASeqCorset/
RNAseqの解析事例=>データでかいとビビってやってない



Bpipeぱっと見便利そう

おまけ2For Deep Learning

- Floydのアカウント作ってみんなでGPU使おうぜ!
- Deel learningの置けるHerokuとのこと。
- アカウント無料のプランでGPUが使えます。AWS+DL環境

Home

Welcome to Floydhub Documentation

Floydhub is Heroku for Deep Learning. A Platform-as-a-Service for training and deploying your models in the cloud with a few simple commands.

Click here to get started.

Also visit the FloydHub Forum for discussions, feature requests and help from the community.

Questions? Reach out to us at contact@floydhub.com

Thank you!

https://www.youtube.com/watch?v=Ny2X_WNxrB4

ググると日本語の情報も結構あります。また、上のプレゼンはわかりやすくて良かったです。